



Adquisició de dades mitjançant Web Scraping

Vicent Tortosa
Big Data Aplicat



1. Introducció

En esta actividad se propone obtener datos de una web de venta de productos donde los precios de los artículos sean susceptibles de fluctuar en el tiempo. Esto quiere decir que se puedan obtener descuentos por las fechas del Black Friday, en Navidades, en enero y otros periodos. Con el objeto de monitorizar los cambios de precios y obtener conclusiones del porque esta fluctuación de precios.

Cada alumno/a seleccionará una página web diferente, no puede haber repeticiones de páginas web a ser analizadas por los diferentes alumnos.

Es importante respetar las políticas de cada sitio web (como el archivo `robots.txt`) y evitar la recolección de datos personales sin consentimiento. Se recomienda seleccionar páginas de e-commerce de productos genéricos (ej: electrónica, libros) donde los datos no estén asociados a usuarios.

2. Objetivos

- Adquisición de datos mediante Web Scraping.
- Limpieza, modificación y enriquecimiento de los datos.
- Guardado de datos en ficheros CSV.
- Registro de *logs* de la ejecución del *script*.
- Envío de correo electrónico con la correcta ejecución o no del *script*.



3. Criterios de evaluación

BÁSICO (6 puntos)

1. **(1 punto)** CSV con estructura completa: Nombre, Descripción, Precio, Divisa, Referencia, URL imagen, URL artículo, timestamp
2. **(1 punto)** Formato CSV: cabeceras dentro del CSV y archivo con nomenclatura fecha{YYYY-MM-DD}-[tienda|alumno].csv
3. **(1 punto)** Extracción de todos los productos de UNA categoría
4. **(1 punto)** Sistema de *logging* funcional (*info, error, warning*)
5. **(1 punto)** Paginación automática en categorías
6. **(1 punto)** Múltiples categorías (mínimo 3 diferentes)

AVANZADO (4 puntos)

7. **(1 punto)** Modularización y código limpio
8. **(1 punto)** Enviar un *email* al correo del alumno indicando si ha ido bien o no la ejecución del *script*.
9. **(1 punto)** Manejo de errores robusto (timeouts, conexión, parsing)
10. **(1 punto)** Si se realizan funciones, seguir las recomendaciones de la PEP 257 (docstrings) y PEP 484 (Type hints) para hacer el código más legible, mantenible y compatible con herramientas de análisis.

4. Requisitos Técnicos

- Lenguaje: Python 3.8+
- Librerías recomendadas: BeautifulSoup4, Requests, csv, Pandas, Logging, SMTPLib
- Entregables: Código Python + CSV generado + Log de ejemplo
- Estructura de proyecto:
 - ├── spider.py
 - ├── requirements.txt
 - ├── samples/ (ejemplos de CSV generados)
 - └── README.md



Ejemplo de Log

2025-01-23 10:30:15 - INFO - Spider iniciado

2025-01-23 10:30:20 - INFO - Categoría 'deportes': 15 productos extraídos

2025-01-23 10:30:25 - ERROR - Timeout en página 3, reintentando...

En caso de no entregarse la práctica en tiempo y forma:

1. La actividad debe ser entregada el mismo día que se realice en el aula en la plataforma Aules. En caso de no ser entregada ese mismo día, se podrá entregar antes de finalizar la siguiente clase del siguiente viernes pero se descontarán 3 puntos del total de la práctica. Si se entrega más tarde del segundo viernes solo se podrá optar a un 5 sobre 10 de nota máxima.